

Многомерна статистика

Многомерни методи за статистическо моделиране

0.1. За мен

- 2017-2022
 - Магистър - Бизнес инженер - специалност Анализ Данни
 - Гентски Университет, Белгия
 - Икономически факултет
- 2022-2026
 - Софтуерен инженер
 - BrightAnalytics (финтек компания)
 - Автоматизация на счетоводни и оперативни доклади
 - Бекенд архитектура, оптимизация на фонові процеси, синхронизация на данни и приложения на изкуствен интелект
- 2026-
 - Асистент и докторант в ТУ
 - Катедра информатика
 - Програмиране, многомерна статистика, квантова информатика



0.2. За курса

Накратко:

- Надграждане на вече усвоени умения за многомерен анализ
- Основи на статистическо моделиране и машинно самообучение
- Приложения и визуализации в Python

Теми:

- 1 Интродукция в статистическото моделиране, метрики и валидация
- 2 Линеино моделиране: обобщен линеен модел, пробит и лог-линеен модел
- 3 Основи за класификация: ковариационна матрица, разстояние на Махаланобис, рангова корелация, частна и множествена корелация, канонична корелация
- 4 Линеен и нелинеен дискриминантен анализ
- 5 Дървовидни модели: класификационни и регресионни дървета
- 6 Клъстерен анализ и йерархичен клъстерен анализ
- 7 Метод на главните компоненти и многомерно скалиране
- 8 Факторен, кореспондентен и латентен семантичен анализ



1.1. Статистическо моделиране

- Есенция на статистическото моделиране. Истинска функция f , с нормално разпределен шум

$$Y = f(X) + \epsilon \quad \epsilon \sim \mathcal{N}(0, \sigma^2)$$

- Разпределение на $Y | X$

$$Y | X \sim \mathcal{N}(f(X), \sigma^2)$$



1.1. Статистическо моделиране

- Оценяване на $f(\mathbf{X})$


$$\hat{Y} = \hat{f}(\mathbf{X})$$

- Очаквана стойност на оценената функция (модел)

$$\mathbb{E}[\hat{f}(\mathbf{X})]$$

- Вариация на оценената функция (модел)

$$\text{Var}[\hat{f}(\mathbf{X})]$$




1.2. Систематична грешка и вариация

- Систематична грешка, вариация и неотстранима грешка


$$\begin{aligned}\mathbb{E}[(Y - \hat{Y})^2] &= \mathbb{E}[Y - \hat{Y}]^2 + \text{Var}[Y - \hat{Y}] \\ &= \mathbb{E}[f(\mathbf{X}) + \epsilon - \hat{f}(\mathbf{X})]^2 + \text{Var}[f(\mathbf{X}) + \epsilon - \hat{f}(\mathbf{X})] \\ &= \underbrace{(f(\mathbf{X}) - \mathbb{E}[\hat{f}(\mathbf{X})])^2}_{\text{Bias}^2} + \underbrace{\text{Var}[\hat{f}(\mathbf{X})]}_{\text{Variance}} + \underbrace{\sigma^2}_{\text{Irreducible error}}\end{aligned}$$

1.2. Систематична грешка и вариация


Висока системна грешка, Висока вариация
(High Bias, High Variance)




Ниска системна грешка, Висока вариация
(Low Bias, High Variance)



Висока системна грешка, Ниска вариация
(High Bias, Low Variance)





Ниска системна грешка, Ниска вариация
(Low Bias, Low Variance)



1.2.1. Баланс между систематична грешка и вариация (bias-variance tradeoff)

- Простите модели имат висока систематична грешка, но ниска вариация
- Гъбавите модели имат ниска систематична грешка, но висока вариация

10 datasets with $N=20$ samples





1.2.1. Баланс между систематична грешка и вариация (bias-variance tradeoff)

- При наличие на повече данни вариацията на модела намалява


$$\text{Var}[\bar{Y}|\mathbf{X}] = \frac{\sigma^2}{N}$$

10 datasets with N=100 samples



1.2.1. Баланс между систематична грешка и вариация (bias-variance tradeoff)

- Не винаги е възможно да набавим повече данни или да опростим модела!!!



1.3. Видове статистическо обучение

- Насочено обучение (supervised learning)
(налична целева променлива)
- Ненасочено обучение (unsupervised learning)
(налични само независими променливи)

1.3. Видове статистическо обучение

- Насочено обучение

- Регресия

- Непрекъсната целева променлива

(напр. височина, тегло)

- Дискретна целева променлива


(напр. бройки)

- Ординална целева променлива

(напр. лошо, средно, отлично)


- Моделираната величина е непрекъсната, дискретна или ординална

(напр. **логистичната регресия** прогнозира вероятности, въпреки че целевата променлива е номинална и се използва за класификация)



1.3. Видове статистическо обучение

- Насочено обучение
 - Класификация
 - Бинарна целева променлива
(напр. спам / не е спам, 0 / 1)
 - Многокласова целева променлива
(напр. куче / котка / птица)





1.3. Видове статистическо обучение

- Ненасочено обучение

- Клъстеризация

(напр. групиране на клиенти или демографски групи по поведение)




1.3. Видове статистическо обучение

- Ненасочено обучение

- Намаляване на размерността

(напр. за опростяване на модела, подбор на най-важните характеристики или елиминирание на зависимостите между променливите)



1.3. Видове статистическо обучение

- Ненасочено обучение
 - Генеративни модели
(напр. синтез на данни)
 - Автоенкодери
(напр. използване на автоенкодери за намаляване на размерността)
 - ...

1.4. Метрики

- Как оценяваме грешката на модела?

- Избор на метрика
- Метод на валидация

- Метрики за регресия:


$$\text{MSE} = \frac{1}{N} \sum_i (y_i - \hat{y}_i)^2 \quad [\text{unit}^2]$$

$$\text{RMSE} = \sqrt{\text{MSE}} \quad [\text{unit}]$$

$$\text{MAE} = \frac{1}{N} \sum_i |y_i - \hat{y}_i| \quad [\text{unit}]$$

$$\text{MAPE} = \frac{100\%}{N} \sum_i \frac{|y_i - \hat{y}_i|}{y_i} \quad [\% \text{ units}]$$

$$R^2 = 1 - \frac{\sum_i^N (y_i - \hat{y}_i)^2}{\sum_i^N (y_i - \bar{y})^2} \quad [\% \text{ обяснена вариация}]$$




1.4. Метрики

- Как оценяваме грешката на модела?
 - Избор на метрика
 - Метод на валидация
- Метрики за регресия с чувствителност към аномалии:

MSE

RMSE

R^2



1.4. Метрики

- Как оценяваме грешката на модела?
 - **Избор на метрика**
 - Метод на валидация
- Метрики за класификация

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}$$



$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Sensitivity (Recall)} = \frac{TP}{TP + FN}$$

$$\text{Specificity} = \frac{TN}{TN + FP}$$

$$\text{NPV} = \frac{TN}{TN + FN}$$

$$\text{AUC} = \int_0^1 \text{TPR}(t) d(\text{FPR}(t))$$



1.4. Метрики

- Как оценяваме грешката на модела?
 - Избор на метрика
 - Метод на валидация
- Метрики за класификация и проблем с дисбаланс на класовете

(напр. прогнозиране на рядка болест с честота 0.5%)

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN} = 99.5\%$$

$$\text{Precision} = \frac{TP}{TP + FP} = 0\% \text{ (undefined)}$$

$$\text{Sensitivity (Recall)} = \frac{TP}{TP + FN} = 0\%$$

$$\text{Specificity} = \frac{TN}{TN + FP} = 100\%$$


$$\text{NPV} = \frac{TN}{TN + FN} = 99.5\%$$

Фокус върху позитивния клас

Precision и **Sensitivity** не се влияят от дисбаланса, когато позитивния клас е малцинствен.

Фокус върху негативния клас

Specificity и **NPV** не се влияят от дисбаланса, когато негативния клас е малцинствен.




1.4. Метрики

- Как оценяваме грешката на модела?
 - **Избор на метрика**
 - Метод на валидация
- Метрики за многокласова класификация:
(принцип 1 срещу всички останали)

$$\text{Macro-average} = \frac{1}{K} \sum_i^K \text{Metric}_i, \quad \text{Metric}_i = \text{метрика за клас } i$$



$$\text{Weighted-average} = \frac{\sum_i^K w_i \cdot \text{Metric}_i}{\sum_i^K w_i}, \quad w_i = \text{честота на клас } i$$

$$\text{Micro-average} = \frac{\sum_i^K \text{TP}_i}{\sum_i^K (\text{TP}_i + \text{FP}_i + \text{FN}_i)}$$



1.5. Валидация



- Как оценяваме грешката на модела?
 - Избор на метрика
 - **Метод на валидация**
- Преобучение (Overfitting)



- Очакваната грешка $\mathbb{E}[(Y - \hat{Y})^2]$ се доминира от вариацията $\text{Var}[\hat{f}]$. (Виж секция 1.2.)

1.5. Валидация


- Как оценяваме грешката на модела?
 - Избор на метрика
 - **Метод на валидация**
- Недообучение (Underfitting)



- Очакваната грешка $\mathbb{E}[(Y - \hat{Y})^2]$ се доминира от систематичната грешка $(f - \mathbb{E}[\hat{f}])^2$. (Виж секция 1.2.)


1.5. Валидация

- Как оценяваме грешката на модела?
 - Избор на метрика
 - **Метод на валидация**
- **Нужен е метод, който да оцени грешката правилно имайки предвид преобучението и недообучението!!!**
 - Висока грешка при недообучение (Underfitting)
 - Висока грешка при преобучение (Overfitting)



1.5. Валидация


- Как оценяваме грешката на модела?
 - Избор на метрика
 - **Метод на валидация**
- **Нужен е метод, който да оцени грешката правилно имайки предвид преобучението и недообучението!!!**
 - Тренировъчната оценка подценява истинската грешка при преобучение (Overfitting)
 - Тестовата оценка дава по-точна представа за истинската грешка



1.5.1. Тренировъчна и тестова оценка

- Как оценяваме грешката на модела?
 - Избор на метрика
 - **Метод на валидация**
- Разделяне на тренировъчни и тестови данни (train-test split)


Тренираме на тренировъчните данни и оценяваме на тестовите данни.



1.5.2. Кръстосана валидация

- Как оценяваме грешката на модела?
 - Избор на метрика
 - **Метод на валидация**
- k-кратна кръстосана валидация (k-fold cross-validation)


Разделяме данните неколkokратно, тренираме на част от тях и тестваме на останалите, като повтаряме процеса.



1.5.2. Кръстосана валидация

- Как оценяваме грешката на модела?
 - Избор на метрика
 - **Метод на валидация**
- k-кратна кръстосана валидация (k-fold cross-validation)

Разделяме данните неколkokратно, тренираме на част от тях и тестваме на останалите, като повтаряме процеса.



1.6. Обобщение

- Каква е разликата между истинската функция и оценената функция?
- Какви са компонентите на очакваната грешка?
- Защо говорим за баланс между систематична грешка и вариация?
- Какво е важно при избора на метрика?
- Защо е важно разделянето на данните на тренировъчни и тестови?